

Estimación de los umbrales de inflación para la estimación del efecto *Pass through*

Para la estimación de los umbrales del modelo TAR se seguirá la metodología propuesta por Chang(1993). Para ello se estima el modelo para cada uno de los umbrales posibles¹ teniendo como regla de decisión para escoger los umbrales verificar cuales son los modelos que minimizan la suma de residuos al cuadrado. Una vez definido el conjunto de umbrales es posible definir los distintos regímenes de inflación que determinarán el efecto *pass through*.

El modelo a estimar es:

$$\Delta\%P_t = \beta_0 + \beta_1\Delta\%P_{t-1} + \beta_2e_t + \delta_a e_t * (\Delta\%P_{t-1} < \tau) + \beta_3\Delta\%P_t^E + \beta_4y_t^{brecha}$$

donde:

$\Delta\%P_t$ Tasa de variación del Índice de Precios al Consumidor

β_0 Componente autónomo de la tasa de inflación

$\Delta\%P_{t-1}$ Componente inercial de la inflación

e_t Tasa de variación del tipo de cambio (tasa de depreciación del tipo de cambio)

$\Delta\%P_t^E$ Tasa de variación del Índice de Precios al Consumidor de Estados Unidos

y_t^{brecha} Brecha relativa del producto respecto del potencial

τ Detona el valor del umbral para el régimen de inflación

$\Delta\%P_{t-1} < \tau$ Variable dicotómica que es 1 en régimen de inflación baja y 0 en régimen de inflación alta

Donde es claro que el uso de la dicotómica separa los regímenes de inflación.

Datos a utilizar

inflación intermensual Guatemala	inflación inercial Guatemala	inflación intermensual Estados Unidos	brecha del producto	Depreciación intermensual Quetzales x USD 1
0.0073	0.0137	0.00400	0.00533	-0.00849
0.0054	0.0073	0.00228	-0.01898	-0.00493
0.0043	0.0054	0.00397	0.01491	0.00659
0.0030	0.0043	0.00452	-0.00784	0.00270
0.0073	0.0030	0.00169	-0.01901	0.00378
0.0087	0.0073	-0.00281	-0.01366	0.00000

Estimación de los distintos modelos

Como se especificó la variable dicotómica $\Delta^{12}P_{t-1} < \tau$ será 1 si el régimen de inflación es bajo o 0 si el régimen de inflación es alto, esto se replica para cada uno de los modelos a estimar.

```
# Creación de todos los posibles umbrales
# Número de umbrales fuera por debajo o arriba de la muestra

umbrales_fuera <- length(inercial) - round(dim(datos)[1] - dim(datos)[1]*0.3, digits = 0)

# posibles umbrales del modelo
```

¹Chang(1993) recomienda usar el 70% de las observaciones cenetales

```

posibles <- sort(inercial)
posibles <- posibles[round((umbrales_fuera/2 + 1), 0):
                    (length(inercial)-round(umbrales_fuera/2,0))]

# Lista de modelos

nombre_modelos <- c()
modelos <- list()
bases <- list()

# Estimación de los modelos por cada umbral

for (i in c(1:length(posibles))) {

  nombre_modelos[i] <- c(sprintf("modelo_%s_%s", i, posibles[i]))

  m <- mutate(datos_modelo,
              d = ifelse(inercial<posibles[i], yes = 0, no = 1))

  bases[[i]] <- m

  modelo <- lm(bases[[i]],
              formula = inf_gt_intermensual ~ 1 +
                    deprec*d + inercial +
                    inf_eua_intermensual + var_brecha - d)

  modelos[[i]] <- modelo
}

names(modelos) <- nombre_modelos

```

Luego de la estimación de los modelos se procede al cálculo de la suma de residuos al cuadrado (ssr) de cada modelo.

```

ssr <- c()

for (i in c(1:length(posibles))) {

  ssr[i] <- sum(modelos[[i]]$residuals^2)

}

```

Identificación de los umbrales

Una vez determinada la ssr se procede a la identificación de los umbrales escogiendo aquellos que minimicen la ssr.

```

# Cargar la función minimos elaborada en el script minimos.R

source("D:/Documentos/PES/Para la tesis/Tesis/Pass through/Código/minimos.R")

```

```

# Una vez se tiene la función se procede a determinar cuales son los umbrales
# del modelo

umbrales <- posibles[ssr %in% minimos(ssr, 4)]

names(modelos[ssr %in% minimos(ssr, 4)])

## [1] "modelo_18_0.0014" "modelo_19_0.0014" "modelo_95_0.0044"
## [4] "modelo_96_0.0044" "modelo_97_0.0044" "modelo_135_0.0056"
## [7] "modelo_176_0.0083" "modelo_177_0.0083"

# Como se observa son los modelos 11 y 12 con inflación de 0.01692999 anual
# los modelo con menor ssr y por lo tanto este es el primer umbral.


# Forma grafica de identificacion del umbral

ggplot() +
  geom_line(aes(y = ssr, x = posibles), colour = "#3F6E9A", size = 1.3) +
  labs(title = "Estimación de los umbrales",
       y = "Suma de residuos al cuadrado", x = "Umbrales posibles",
       caption = "Elaboración propia") +

  geom_point(aes(x = umbrales,
                 y = ssr[ssr %in% minimos(ssr, 4)]), shape = 1, colour = "red",
             size = 5, stroke = 1.7) +

  theme_classic(base_size = 18)

```



Estimación del modelo con dos umbrales, tres regímenes

Una vez determinado el conjunto de umbrales se procede a la estimación del modelo TAR con tres regímenes inflacionarios.

La nueva especificación es:

$$\Delta\%P_t = \beta_0 + \beta_1\Delta\%P_{t-1} + \beta_2e_t + \delta_a e_t * (\Delta\%P_{t-1} < 0.016929) + \delta_b e_t * (0.016929 \leq \Delta\%P_{t-1} < 0.05409) + \beta_3\Delta\%P_t^E + \beta_4 y_t^{brecha}$$

En este caso ($0.016929 \leq \Delta\%P_{t-1} < 0.05409$) la dicotómica que es 1 si nos encontramos en el régimen de inflación media y es 0 si nos encontramos en el régimen de inflación alta, esto con el fin de establecer el régimen de inflación baja como el escenario base.

```
datos_TAR <- datos_modelo %>%
  mutate(dmen = ifelse(inercial < 0.0014, yes = 1, no = 0),
         dentre = ifelse(inercial >= 0.0014 & inercial < 0.0083,
                        yes = 1, no = 0))

# Por la forma en la que están construidas las dicotómicas el escenario base
# Es el escenario de inflación baja

attach(datos_TAR)
```

```
## The following object is masked _by_ .GlobalEnv:
##
##      inercial

TAR <- lm(datos_TAR, formula = inf_gt_intermensual ~ 1 +
          deprec*dmen + deprec*dentre +
          inercial + inf_eua_intermensual + var_brecha - dmen - dentre)

detach(datos_TAR)

summary(TAR)

##
## Call:
## lm(formula = inf_gt_intermensual ~ 1 + deprec * dmen + deprec *
##     dentre + inercial + inf_eua_intermensual + var_brecha - dmen -
##     dentre, data = datos_TAR)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.0109970 -0.0023787 -0.0003471  0.0021251  0.0142536
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.002534   0.000386   6.564 3.02e-10 ***
## deprec         0.117002   0.082497   1.418 0.157369
## inercial       0.327106   0.061335   5.333 2.17e-07 ***
## inf_eua_intermensual 0.237567   0.065732   3.614 0.000365 ***
## var_brecha    -0.024386   0.017243  -1.414 0.158538
## deprec:dmen    -0.261588   0.126205  -2.073 0.039227 *
## deprec:dentre  -0.111955   0.095536  -1.172 0.242375
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.004023 on 249 degrees of freedom
## Multiple R-squared:  0.1917, Adjusted R-squared:  0.1722
## F-statistic:  9.84 on 6 and 249 DF, p-value: 9.756e-10
```

Resultados obtenidos

Variable	Coefficiente	Error estándar
$\Delta\%P_{t-1}$	0.327106***	0.061335
e_t	0.117002	0.117002
$\delta_a e_t * (\Delta\%P_{t-1} < 0.016929)$	-0.261588 .	0.126205
$\delta_b e_t * (0.016929 \leq \Delta\%P_{t-1} < 0.05409)$	-0.111955	0.095536
$\Delta\%P_t^E$	0.237567***	0.065732

Comprobación de los supuestos

Normalidad


```
tseries::jarque.bera.test(TAR$residuals)
```

```
## Registered S3 method overwritten by 'quantmod':  
##   method      from  
##   as.zoo.data.frame zoo
```

```
##  
##   Jarque Bera Test  
##  
## data:  TAR$residuals  
## X-squared = 10.332, df = 2, p-value = 0.005708
```

```
## 'stat_bin()' using 'bins = 30'. Pick better value with 'binwidth'.
```

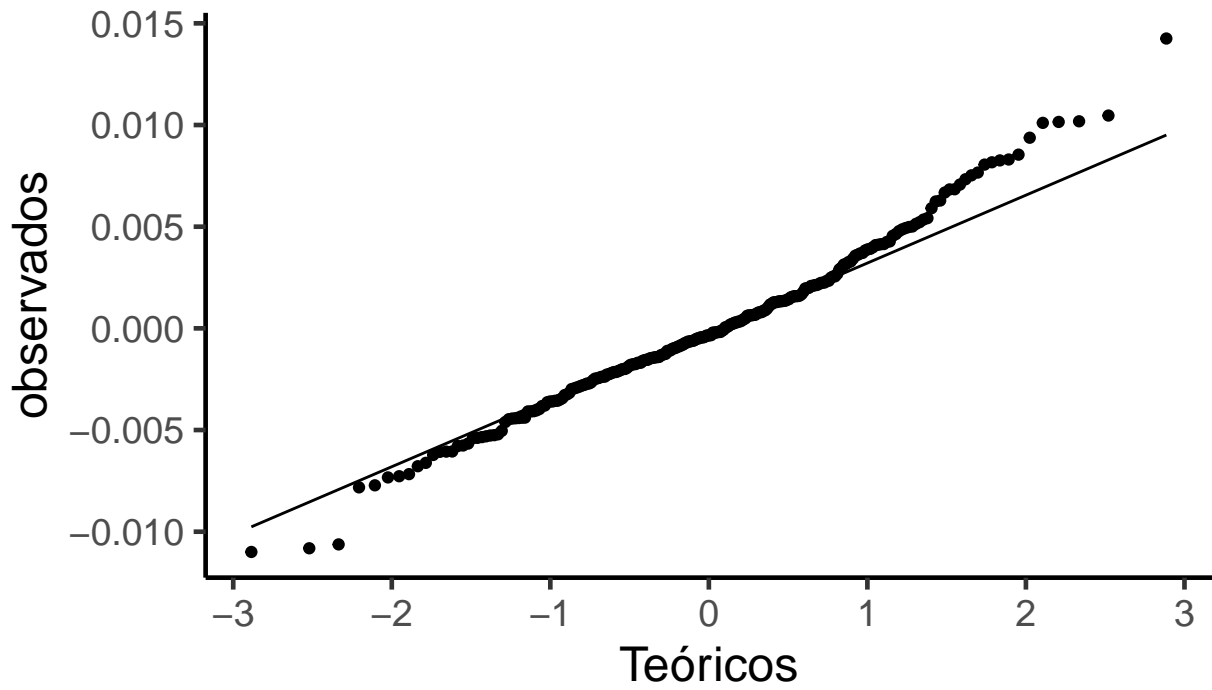
Histograma de los residuos



Elaboración propia

```
ggplot(data.frame(TAR$residuals), aes(sample = TAR$residuals)) +  
  stat_qq(distribution = qnorm) + stat_qq_line() +  
  labs(title = "Gráfico cuantil-cuantil", y = "observados", x = "Teóricos",  
        caption = "Elaboración propia") +  
  theme_classic(base_size = 18)
```

Gráfico cuantil–cuantil



Elaboración propia

Autocorrelación

```
lmtest::bgtest(TAR)
```

```
##  
## Breusch-Godfrey test for serial correlation of order up to 1  
##  
## data: TAR  
## LM test = 1.196, df = 1, p-value = 0.2741
```

Heterocedasticidad

```
lmtest::bptest(TAR)
```

```
##  
## studentized Breusch-Pagan test  
##  
## data: TAR  
## BP = 6.6265, df = 6, p-value = 0.3568
```

Multicolinealidad

```
car::vif(TAR)

## there are higher-order terms (interactions) in this model
## consider setting type = 'predictor'; see ?vif

##           deprec           inercial inf_eua_intermensual
##      4.734831          1.161352          1.048666
##      var_brecha      deprec:dmen      deprec:dentre
##      1.022118          1.782053          3.871301
```

Simulaciones de choques cambiarios


```
inf_alta <- c(0)
lapso <- 10

# Coeficiente del efecto traspaso en régimen de infalción baja

coef_alta <- 0.05689
coef_inercial <- 0.31947
choque <- 1

for (i in c(2:lapso)) {
  if(i == 2){
    inf_alta[i] <- coef_alta*choque
  }else{
    inf_alta[i] <- inf_alta[i-1]*coef_inercial
  }
}

plot(inf_alta)
lines(y = inf_alta, x = c(1:lapso))
```

```
inf_alta <- inf_alta + c(rep(1:1, 10))  
total_inf_alta <- prod(inf_alta[2:lapso]) - 1  
total_inf_alta
```

```
## [1] 0.08529567
```